

UNIVERSIDADE CATÓLICA DE PELOTAS  
CENTRO DE CIÊNCIAS SOCIAIS E TECNOLÓGICAS  
MESTRADO EM ENGENHARIA ELETRÔNICA E COMPUTAÇÃO

PEDRO DA SILVEIRA SAYAO LOBATO

**Uso de técnicas de aprendizado de máquina  
no apoio ao diagnóstico do transtorno de  
ansiedade generalizada de crianças em  
idade pré-escolar**

Dissertação apresentada como requisito parcial para  
a obtenção do grau de Mestre em Engenharia  
Eletrônica e Computação

Orientador: Prof. Dr. Sérgio José Melo de Almeida

Pelotas  
2026

## **CIP — CATALOGAÇÃO NA PUBLICAÇÃO**

Silveira Sayao Lobato, Pedro da

Uso de técnicas de aprendizado de máquina no apoio ao diagnóstico do transtorno de ansiedade generalizada de crianças em idade pré-escolar / Pedro da Silveira Sayao Lobato. – Pelotas: 2026.

49 f.: il.

Dissertação (mestrado) – Universidade Católica de Pelotas. 2026. Orientador: Sérgio José Melo de Almeida.

1. Aprendizado de máquina. 2. Transtorno de ansiedade generalizada. 3. Classificação. 4. Base de dados. I. José Melo de Almeida, Sérgio. II. Título.

**UNIVERSIDADE CATÓLICA DE PELOTAS**

Reitor: Prof. José Carlos Pereira Bachettini Júnior

Pró-Reitora Acadêmica: Profa. Moema Nudilemon Chatkin

Coordenador de Pesquisa e Pós-Graduação Stricto Sensu: Prof. Ricardo Tavares Pinheiro

Diretor do Centro de Ciências Sociais e Tecnológicas: Prof. Fábio Raniere da Silva Mendes

Coordenadora do Mestrado em Engenharia Eletrônica e Computação: Profa. Miriam Blank Born

*“If I have seen farther than others,  
it is because I stood on the shoulders of giants.”*

— SIR ISAAC NEWTON

## **AGRADECIMENTOS**

Ao meu orientador, Prof. Dr. Sérgio José Melo de Almeida, pela orientação, paciência e disponibilidade ao longo deste trabalho.

Aos membros da banca, Profa. Dra. Miriam Blank Born e Prof. Dr. Edécio Fernando Iepsen, pelas contribuições e pelo tempo dedicado à avaliação desta dissertação.

À minha mãe, Clarice da Silveira Siedler, e ao meu pai, Procópio Dame Sayao Lobato, por sempre me incentivarem e apoiarem nos estudos.

Ao meu irmão, Marcelo da Silveira Siedler, por ter me direcionado para a área de TI, e à minha irmã, Renata da Silveira Siedler, por estar sempre presente.

À minha namorada, Glória Henzel Ferreira, pelo apoio constante em todos os momentos.

## RESUMO

O diagnóstico do transtorno de ansiedade generalizada (GAD) em crianças pré-escolares é um processo complexo, demorado e desgastante para profissionais de saúde, crianças e familiares, sobretudo pela dependência de instrumentos extensos como a entrevista PAPA. Este trabalho investiga a aplicação de algoritmos de aprendizado de máquina na predição do risco de GAD, utilizando dados clínicos de 287 crianças entre 2 e 6 anos, extraídos dessa entrevista. Foram comparados os algoritmos XGBoost, SVM e ADTree, combinados a doze técnicas de balanceamento de classes, dado o forte desequilíbrio entre casos positivos e negativos característico de bases de triagem psiquiátrica. O XGBoost apresentou o melhor desempenho, com Kappa de 0,372 utilizando a técnica BorderlineSMOTE, superando os demais algoritmos avaliados. Um experimento de robustez por simulação de Monte Carlo evidenciou que os casos de fronteira permanecem difíceis de classificar mesmo sob reamostragem repetida, delimitando um teto de desempenho associado ao tamanho reduzido da amostra. A análise de importância de atributos identificou o número de prejuízos funcionais como o preditor mais relevante do transtorno. Os resultados indicam que os modelos desenvolvidos são úteis como ferramentas auxiliares de triagem, capazes de priorizar crianças em risco para avaliação especializada, sem substituir o julgamento clínico.

**Palavras-chave:** Aprendizado de máquina. transtorno de ansiedade generalizada. classificação. base de dados.

## ABSTRACT

The diagnosis of Generalized Anxiety Disorder (GAD) in preschool children is a complex, time-consuming, and demanding process for healthcare professionals, children, and families, largely due to reliance on lengthy instruments such as the PAPA interview. This work investigates the application of machine learning algorithms to predict the risk of GAD, using clinical data from 287 children aged 2 to 6 years, extracted from this interview. The XGBoost, SVM, and ADTree algorithms were compared, combined with twelve class balancing techniques, given the strong imbalance between positive and negative cases typical of psychiatric screening datasets. XGBoost achieved the best performance, with a Kappa of 0.372 using the BorderlineSMOTE technique, outperforming the other algorithms evaluated. A robustness experiment based on Monte Carlo simulation showed that borderline cases remain difficult to classify even under repeated resampling, delimiting a performance ceiling associated with the limited sample size. Feature importance analysis identified the number of functional impairments as the most relevant predictor of the disorder. The results indicate that the developed models are useful as auxiliary screening tools, capable of prioritizing at-risk children for specialized evaluation, without replacing clinical judgment.

**Keywords:** Machine Learning. Generalized Anxiety Disorder. PAPA Interview. Pediatric Screening. XGBoost.

**Keywords:** Aprendizado de máquina. transtorno de ansiedade generalizada. classificação. base de dados.

## LISTA DE ABREVIATURAS E SIGLAS

|                 |                                                                     |
|-----------------|---------------------------------------------------------------------|
| ABNT            | Associação Brasileira de Normas Técnicas                            |
| ADTree          | Alternating Decision Tree (Árvore de Decisão Alternada)             |
| ADASYN          | Adaptive Synthetic Sampling                                         |
| AUC             | Area Under the Curve (Área Sob a Curva)                             |
| CBCL            | Child Behavior Checklist                                            |
| BorderlineSMOTE | Borderline Synthetic Minority Over-sampling Technique               |
| CV              | Cross-Validation (Validação Cruzada)                                |
| DSM             | Diagnostic and Statistical Manual of Mental Disorders               |
| F1              | F1-Score (Média Harmônica entre Precisão e Sensibilidade)           |
| GAD             | Generalized Anxiety Disorder (Transtorno de Ansiedade Generalizada) |
| HistGBM         | Histogram-based Gradient Boosting Machine                           |
| IC              | Intervalo de Confiança                                              |
| IHT             | Instance Hardness Threshold                                         |
| KNN             | K-Nearest Neighbors (K-Vizinhos Mais Próximos)                      |
| ML              | Machine Learning (Aprendizado de Máquina)                           |
| NearMiss        | Near Miss Undersampling                                             |
| ODD             | Oppositional Defiant Disorder (Transtorno Desafiador Opositivo)     |
| PAPA            | Preschool Age Psychiatric Assessment                                |
| PAS             | Preschool Anxiety Study                                             |
| PTRTS           | PAPA Test-Retest Study                                              |
| ROC             | Receiver Operating Characteristic                                   |
| RUS             | Random Undersampling (Subamostragem Aleatória)                      |
| RUSBoost        | Random Undersampling Boost                                          |
| SAD             | Separation Anxiety Disorder (Transtorno de Ansiedade de Separação)  |

|            |                                                        |
|------------|--------------------------------------------------------|
| SHAP       | SHapley Additive exPlanations                          |
| SMOTE      | Synthetic Minority Over-sampling Technique             |
| SMOTE-ENN  | SMOTE com Edited Nearest Neighbours                    |
| SMOTETomek | SMOTE com Tomek Links                                  |
| SVM        | Support Vector Machine (Máquina de Vetores de Suporte) |
| TDAH       | Transtorno de Déficit de Atenção e Hiperatividade      |
| XGBoost    | Extreme Gradient Boosting                              |



## LISTA DE FIGURAS

|                                                                                                                                                                                                                                                                                                    |    |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| Figura 3.1 Visão geral do fluxo metodológico adotado, da base original ao comparativo final de modelos. ....                                                                                                                                                                                       | 23 |
| Figura 4.1 Espectro de trade-off entre sensibilidade e especificidade nas quatro configurações do XGBoost. As configurações se distribuem em um contínuo, do extremo conservador ( <i>BorderlineSMOTE</i> ) ao extremo de máxima detecção ( <i>GridSearch</i> otimizado para <i>recall</i> ). .... | 37 |
| Figura 4.2 Curvas ROC comparativas para as três configurações mais representativas: XGBoost com <i>BorderlineSMOTE</i> (AUC 0,763), XGBoost com SMOTE (AUC 0,751) e SVM com SMOTE (AUC 0,678). A linha diagonal representa um classificador aleatório. ....                                        | 38 |

## LISTA DE TABELAS

|                                                                                                                                                                                                                     |    |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| Tabela 2.1 Síntese comparativa entre os trabalhos correlatos da literatura e a proposta desta dissertação.....                                                                                                      | 21 |
| Tabela 4.1 Quantificação de valores ausentes na base original.....                                                                                                                                                  | 32 |
| Tabela 4.2 Relação de variáveis descartadas durante o pré-processamento.....                                                                                                                                        | 32 |
| Tabela 4.3 Distribuição final da classe alvo após o pré-processamento.....                                                                                                                                          | 33 |
| Tabela 4.4 Hiperparâmetros selecionados pela busca em grade, por algoritmo e técnica de balanceamento.....                                                                                                          | 33 |
| Tabela 4.5 Comparativo de critérios de calibração do limiar de decisão, XGBoost com SMOTE. O limiar $t$ varia por critério, enquanto as métricas discriminativas subjacentes permanecem constantes. ....            | 34 |
| Tabela 4.6 Desempenho individual dos modelos para o GAD, validação cruzada estratificada de 10 partições, com limiar de decisão padrão ( $t = 0,50$ ).*                                                             | 35 |
| Tabela 4.7 Melhor coeficiente Kappa por algoritmo, com limiar de decisão padrão ( $t = 0,50$ ). ....                                                                                                                | 36 |
| Tabela 4.8 Compromisso entre concordância e detecção no XGBoost, com limiar de decisão padrão ( $t = 0,50$ ). ....                                                                                                  | 36 |
| Tabela 4.9 Impacto da correção do vazamento de dados no experimento de Monte Carlo. ....                                                                                                                            | 39 |
| Tabela 4.10 Resultados da simulação de Monte Carlo, 200 simulações com sorteio de 15 dos 20 casos difíceis e avaliação sobre 43 amostras (38 do teste honesto mais 5 hard samples remanescentes por iteração). .... | 40 |
| Tabela 4.11 Cinco atributos de maior importância preditiva para o GAD segundo o XGBoost.                                                                                                                            | 41 |
| Tabela 4.12 Nós de decisão selecionados pela ADTree para o GAD em Carpenter et al. (2016).....                                                                                                                      | 41 |
| Tabela 5.1 Cronograma de atividades previstas até dezembro de 2026. ....                                                                                                                                            | 47 |

## SUMÁRIO

|                                                                                  |           |
|----------------------------------------------------------------------------------|-----------|
| <b>1 INTRODUÇÃO .....</b>                                                        | <b>13</b> |
| <b>1.1 Contextualização e Justificativa.....</b>                                 | <b>13</b> |
| <b>1.2 Problema de Pesquisa .....</b>                                            | <b>14</b> |
| <b>1.3 Objetivos .....</b>                                                       | <b>15</b> |
| 1.3.1 Objetivo Geral.....                                                        | 15        |
| 1.3.2 Objetivos Específicos .....                                                | 15        |
| <b>1.4 Organização do Trabalho.....</b>                                          | <b>15</b> |
| <b>2 FUNDAMENTAÇÃO TEÓRICA E TRABALHOS RELACIONADOS .....</b>                    | <b>16</b> |
| <b>2.1 Transtorno de Ansiedade Generalizada (GAD) na Primeira Infância .....</b> | <b>16</b> |
| <b>2.2 Avaliação Psiquiátrica Infantil e a Entrevista PAPA .....</b>             | <b>17</b> |
| <b>2.3 Aprendizado de Máquina na Saúde Mental .....</b>                          | <b>18</b> |
| 2.3.1 Aprendizado Supervisionado e Classificação .....                           | 19        |
| 2.3.2 Desafios: Desbalanceamento de Classes e Interpretabilidade .....           | 19        |
| <b>2.4 Trabalhos Relacionados e Lacunas da Literatura .....</b>                  | <b>20</b> |
| <b>3 METODOLOGIA .....</b>                                                       | <b>22</b> |
| <b>3.1 Visão Geral do Fluxo Metodológico .....</b>                               | <b>22</b> |
| <b>3.2 Base de Dados e Aspectos Éticos.....</b>                                  | <b>23</b> |
| 3.2.1 Entrevista PAPA e Caracterização da Amostra.....                           | 23        |
| 3.2.2 Seleção e Codificação de Variáveis.....                                    | 24        |
| 3.2.3 Aspectos Éticos .....                                                      | 25        |
| <b>3.3 Pré-processamento e Estratégias de Balanceamento .....</b>                | <b>25</b> |
| 3.3.1 Tratamento de Valores Ausentes.....                                        | 25        |
| 3.3.2 Normalização e Codificação de Atributos .....                              | 26        |
| 3.3.3 Estratégias de Balanceamento.....                                          | 26        |
| <b>3.4 Algoritmos de Aprendizado de Máquina Avaliados .....</b>                  | <b>27</b> |
| 3.4.1 Support Vector Machine .....                                               | 27        |
| 3.4.2 XGBoost .....                                                              | 28        |
| 3.4.3 Métodos de Ensemble .....                                                  | 28        |
| 3.4.4 ADTree.....                                                                | 28        |
| <b>3.5 Validação Experimental e Critérios de Avaliação .....</b>                 | <b>29</b> |
| 3.5.1 Validação Cruzada Aninhada (Nested CV).....                                | 29        |
| 3.5.2 Métrica Primária, Limiares e Teste de Robustez (Monte Carlo) .....         | 29        |
| <b>3.6 Ferramentas e Ambiente Computacional .....</b>                            | <b>30</b> |
| <b>4 RESULTADOS EXPERIMENTAIS E DISCUSSÃO .....</b>                              | <b>32</b> |
| <b>4.1 Consolidação da Base e Pré-processamento .....</b>                        | <b>32</b> |
| <b>4.2 Desempenho dos Modelos e Comparativo de Algoritmos .....</b>              | <b>33</b> |
| 4.2.1 Hiperparâmetros e Calibração do Limiar de Decisão .....                    | 33        |
| 4.2.2 Métricas Discriminativas (Kappa, Sensibilidade, AUC/ROC) .....             | 34        |
| 4.2.3 Validação de Robustez (Simulação de Monte Carlo em Hard Samples) .....     | 39        |
| <b>4.3 Importância das Características Preditivas .....</b>                      | <b>40</b> |
| <b>4.4 Discussão dos Achados e Impacto Clínico .....</b>                         | <b>42</b> |
| <b>4.5 Limitações do Estudo.....</b>                                             | <b>43</b> |
| <b>5 CONCLUSÃO E PRÓXIMOS PASSOS.....</b>                                        | <b>45</b> |
| <b>5.1 Conclusões .....</b>                                                      | <b>45</b> |
| <b>5.2 Principais Contribuições .....</b>                                        | <b>45</b> |
| <b>5.3 Trabalhos Futuros.....</b>                                                | <b>46</b> |
| <b>CRONOGRAMA .....</b>                                                          | <b>47</b> |
| <b>CRONOGRAMA .....</b>                                                          | <b>47</b> |

**REFERÊNCIAS..... 48**

# 1 INTRODUÇÃO

## 1.1 Contextualização e Justificativa

A ansiedade é, antes de tudo, uma resposta biológica adaptativa de defesa. Ela funciona como um sistema de alerta que prepara o corpo para reagir a situações de perigo, desafio e desconforto (VIANA, 2010). Sentir medo ou preocupação não é apenas esperado, mas necessário para a segurança e o desenvolvimento do indivíduo ao longo da vida.

Existe, porém, uma diferença entre o medo comum, inerente ao crescimento, e aquele que se torna um problema de saúde. Essa distinção não está no sentimento em si, mas no seu exagero e na sua desregulação. Quando a reação emocional se manifesta de forma desproporcional ao que a desencadeou, persiste além do esperado e prejudica as atividades cotidianas, ela deixa de ser uma proteção e passa a ser considerada um transtorno (ASBAHR, 2004; CAIRES; SHINOHARA, 2010).

Por muito tempo prevaleceu a ideia de que crianças pequenas, sobretudo na fase pré-escolar (entre 2 e 5 anos), estariam protegidas de transtornos psiquiátricos, e que seus medos seriam apenas fases passageiras do desenvolvimento (EGGER; ANGOLD, 2006). As evidências atuais, no entanto, mostram o contrário. Crianças também possuem quadros de ansiedade não identificados, que podem deixar de ser passageiros e se tornar condições crônicas associadas a psicopatologias na vida adulta. (ASBAHR, 2004; CARPENTER et al., 2016).

Os dados epidemiológicos reforçam essa preocupação. Estima-se que cerca de 10% das crianças em idade escolar e pré-escolar apresentem quadros de ansiedade que exigem atenção clínica (EGGER; ANGOLD, 2006; ASBAHR, 2004). Entre as manifestações mais comuns nessa faixa etária está o GAD (Transtorno de Ansiedade Generalizada) (CARPENTER et al., 2016).

Nas últimas décadas, o avanço da inteligência artificial, e em particular do aprendizado de máquina, abriu novas possibilidades em diversas áreas, entre elas a identificação de transtornos mentais. No caso da ansiedade, essas técnicas têm recebido atenção por conseguirem reconhecer padrões complexos e não lineares em dados clínicos (CARPENTER et al., 2016; ESKANDAR, 2024). Na psiquiatria infantil, elas vêm sendo usadas para otimizar instrumentos diagnósticos tradicionais, transformando entrevistas longas e complexas em ferramentas de triagem mais curtas e aplicáveis à rotina clínica (CARPENTER et al., 2016). Quando combinadas a modelos interpretáveis, essas técnicas podem oferecer não só bom desempenho preditivo, mas também a transparência necessária para seu uso responsável em saúde mental (CARUANA et

al., 2015; ESKANDAR, 2024).

## 1.2 Problema de Pesquisa

Identificar transtornos de ansiedade na prática clínica não é uma tarefa simples. Ao contrário de adultos e adolescentes, crianças em idade pré-escolar têm capacidade verbal e cognitiva limitada para compreender e relatar sintomas que são, por natureza, subjetivos. Elas raramente conseguem verbalizar que estão ansiosas e, em vez disso, manifestam seu sofrimento por meio de comportamentos, queixas físicas ou alterações no sono. Soma-se a isso o caráter internalizante da ansiedade que, enquanto transtornos externalizantes, como agressividade ou hiperatividade, chamam rapidamente a atenção de pais e professores, a criança ansiosa tende a se retrair, sofrendo de forma silenciosa e passando despercebida pelos adultos ao seu redor (MCGINNIS et al., 2019; EGGER; ANGOLD, 2006).

Essa dificuldade diagnóstica se reflete diretamente no acesso ao cuidado. Estudos com amostras comunitárias mostram que apenas 3,8% das crianças pré-escolares com transtornos de ansiedade recebem tratamento adequado (FRANZ et al., 2013). Mesmo em faixas etárias mais amplas, a ansiedade continua sendo subtratada em relação a outros transtornos, pois enquanto quase 80% das crianças com depressão são atendidas, esse número cai para cerca de 59% entre as que têm ansiedade (GHANDOUR et al., 2019).

Uma das principais razões para essa lacuna é a ausência de instrumentos de triagem que sejam, ao mesmo tempo, rápidos e precisos para uso na atenção primária (CARPENTER et al., 2016; MENG; WIZNITZER, 2024). Atualmente, uma das referências para o diagnóstico é a *Preschool Age Psychiatric Assessment* (PAPA), entrevista semiestruturada aplicada aos cuidadores que avalia diversos domínios psicopatológicos em crianças pré-escolares. Apesar de consolidada e validada, sua aplicação exige treinamento intensivo e leva cerca de 100 minutos, o que a torna pouco viável para a rotina de clínicas pediátricas e escolas (EGGER et al., 2006a). Ferramentas de triagem mais breves, como o CBCL 1.5-5 e a *Preschool Spence Anxiety Scale*, por outro lado, muitas vezes ainda são longas demais ou pouco específicas para transtornos individuais como o GAD (ACHENBACH; RESCORLA, 2000a; SPENCE et al., 2001).

## 1.3 Objetivos

### 1.3.1 Objetivo Geral

Esta dissertação tem como objetivo geral investigar e validar a aplicação de algoritmos de aprendizado de máquina na predição do risco de GAD em crianças pré-escolares, a partir dos dados da entrevista clínica *Preschool Age Psychiatric Assessment* (PAPA), buscando identificar os preditores mais relevantes para a otimização da triagem diagnóstica.

### 1.3.2 Objetivos Específicos

- Aplicar técnicas de pré-processamento e balanceamento nos dados clínicos, visando contornar o desbalanceamento dos rótulos, típico em dados de triagem psiquiátrica;
- Treinar e comparar o desempenho de diferentes técnicas no aprendizado supervisionado para a detecção precoce do GAD;
- Identificar o subconjunto de características que permita encontrar um modelo preditivo com melhor desempenho, proporcionando um instrumento de triagem mais simples.

## 1.4 Organização do Trabalho

Esta dissertação está organizada em cinco capítulos. O Capítulo 2 apresenta a fundamentação teórica e os trabalhos relacionados, abordando os transtornos de ansiedade na primeira infância, os instrumentos de avaliação disponíveis e os fundamentos do aprendizado de máquina aplicado à saúde mental. O Capítulo 3 descreve a metodologia empregada, incluindo a caracterização da amostra, o pré-processamento dos dados e as técnicas de modelagem utilizadas. O Capítulo 4 apresenta os resultados obtidos, incluindo o desempenho dos modelos, as análises de robustez e a comparação com trabalhos da literatura. Por fim, o Capítulo 5 traz as conclusões, as principais contribuições e as perspectivas para trabalhos futuros.

## **2 FUNDAMENTAÇÃO TEÓRICA E TRABALHOS RELACIONADOS**

Este capítulo reúne a fundamentação teórica que sustenta este trabalho. Ele aborda os aspectos clínicos do GAD na primeira infância, os instrumentos de avaliação utilizados, os conceitos fundamentais de aprendizado de máquina e as aplicações prévias dessas técnicas no campo da saúde mental.

### **2.1 Transtorno de Ansiedade Generalizada (GAD) na Primeira Infância**

Do ponto de vista neurobiológico, a resposta de ansiedade envolve a ativação de circuitos cerebrais ligados à percepção de ameaça, com destaque para a amígdala e suas conexões com o córtex pré-frontal, estruturas ainda em maturação durante os primeiros anos de vida (AS-BAHR, 2004). Essa imaturidade dos mecanismos de regulação emocional ajuda a explicar por que a criança tem maior dificuldade em modular o medo e a preocupação, e por que quadros ansiosos nessa fase tendem a se expressar de maneira difusa e pouco específica. Fatores temperamentais, como a inibição comportamental (a tendência a reagir com cautela e retraimento diante de situações novas), somam-se a essa base biológica e figuram entre os precursores mais consistentes do desenvolvimento de transtornos de ansiedade (EGGER; ANGOLD, 2006).

Entre os quadros ansiosos mais frequentes na primeira infância está o GAD, caracterizado por uma preocupação crônica, difusa e incontrolável, que não se restringe a uma situação, objeto ou evento específico. Diferentemente dos medos pontuais e esperados para a idade, a criança com GAD vive em estado de apreensão e hipervigilância constantes. Nessa fase, o transtorno costuma se manifestar por preocupações exageradas com o próprio desempenho ou com a rotina, levando a criança a assumir uma postura rígida, muitas vezes descrita na clínica como a de um "pequeno adulto" (EGGER; ANGOLD, 2006).

Estudos epidemiológicos indicam que o GAD é uma das manifestações ansiosas mais comuns nos primeiros anos de vida. Dados de amostras comunitárias norte-americanas apontam que cerca de 4,7% das crianças em idade pré-escolar preenchem os critérios diagnósticos completos para o transtorno, considerando tanto o nível de sintomas quanto o prejuízo funcional associado (CARPENTER et al., 2016). Apesar dessa prevalência, sua identificação clínica esbarra em barreiras que resultam em subdiagnóstico (CARPENTER et al., 2016).

A principal dificuldade está na imaturidade cognitiva e verbal da criança pequena, que raramente consegue expressar suas preocupações com clareza. O sofrimento acaba transbordando para o corpo e para o comportamento. Apoiada na análise de instrumentos como a



entrevista PAPA, a literatura mostra que os sintomas mais preditivos do GAD nessa fase incluem medos intrusivos e incontroláveis, sustos súbitos sem motivo aparente, tensão muscular visível em momentos de nervosismo e dificuldade de manter a atenção, mesmo em atividades do interesse da criança (CARPENTER et al., 2016).

Esse conjunto de manifestações somáticas, somado à natureza silenciosa e internalizante do transtorno, faz com que a criança ansiosa seja muitas vezes confundida com uma criança apenas tímida, retraída ou "de bom comportamento", o que mascara o quadro (EGGER; ANGOLD, 2006; CARPENTER et al., 2016). É justamente nesse ponto cego da observação de pais e professores que se justifica o desenvolvimento de ferramentas de triagem baseadas em dados, capazes de rastrear o transtorno de forma precoce e evitar que a criança siga sem o encaminhamento adequado (CARPENTER et al., 2016; ZHAI et al., 2025).

## 2.2 Avaliação Psiquiátrica Infantil e a Entrevista PAPA

No campo da psicopatologia, os instrumentos de avaliação são questionários estruturados que buscam detectar eventos psicológicos, com a finalidade de mensurar comportamentos e quantificar o prejuízo funcional de um paciente. Essas ferramentas buscam oferecer uma base padronizada que apoie o julgamento clínico, permitindo distinguir comportamentos normativos e transitórios de quadros efetivamente patológicos (MIAN; DARLING; CARTER, 2025).

Na primeira infância, essa avaliação encontra um obstáculo particular. Como a criança pequena não consegue relatar com precisão a duração ou a intensidade de seus medos, a avaliação depende quase inteiramente de uma abordagem multi-informante, baseada na observação de pais, cuidadores e educadores (EGGER; ANGOLD, 2004; MIAN; DARLING; CARTER, 2025). Os instrumentos utilizados nesse cenário costumam ser divididos em duas categorias, as listas de verificação de sintomas (*checklists*) e as entrevistas diagnósticas estruturadas (EGGER; ANGOLD, 2004).

As listas de verificação, como o *Child Behavior Checklist* (CBCL), são amplamente usadas na triagem por serem rápidas e preenchidas diretamente pelos pais, geralmente em 15 a 20 minutos. Por dependerem apenas do autorrelato, sem a mediação de um profissional, esses questionários são suscetíveis ao viés do informante, pois as respostas podem ser influenciadas pela própria ansiedade ou pelo estilo parental de quem responde, o que leva a superestimar sintomas comuns ou a não captar o sofrimento silencioso da criança (ACHENBACH; RESCORLA, 2000b; EGGER; ANGOLD, 2004).

A entrevista *Preschool Age Psychiatric Assessment* (PAPA) surge como alternativa a

essa limitação. Desenvolvida por Egger e Angold, é uma entrevista diagnóstica estruturada voltada à avaliação da psicopatologia em crianças de 2 a 5 anos (EGGER et al., 2006b). Diferentemente dos questionários preenchidos pelos pais, a PAPA é conduzida por um entrevistador treinado, que faz as perguntas aos cuidadores mas mantém sob sua responsabilidade o julgamento sobre a presença de cada sintoma, seguindo um glossário com regras operacionais (EGGER; ANGOLD, 2004).

Durante a aplicação, pede-se aos pais exemplos concretos do comportamento da criança nos últimos três meses. Um sintoma só é codificado como positivo quando o relato atinge a gravidade, a frequência e a duração definidas no glossário (EGGER; ANGOLD, 2004; CARPENTER et al., 2016). Essa estrutura reduz o viés do respondente e confere à PAPA uma confiabilidade de teste-reteste comparável à de entrevistas aplicadas em adultos (EGGER et al., 2006b).

Apesar de ser considerada um instrumento de referência, a PAPA impõe uma barreira prática importante. Sua aplicação completa leva, em média, de uma a duas horas e exige treinamento clínico intensivo (CARPENTER et al., 2016; EGGER; ANGOLD, 2004). Essa demanda de tempo inviabiliza seu uso em triagens de larga escala, seja na atenção primária, seja no ambiente escolar. É justamente nessa lacuna entre a precisão diagnóstica e a viabilidade de aplicação que o aprendizado de máquina se destaca, sendo capaz de extrair os itens com maior poder preditivo de instrumentos extensos como a PAPA e transformá-los em ferramentas de triagem mais rápidas (CARPENTER et al., 2016).

## 2.3 Aprendizado de Máquina na Saúde Mental

O aprendizado de máquina é o campo da inteligência artificial que desenvolve sistemas capazes de aprender a partir de dados e melhorar seu desempenho com a experiência, sem depender de regras explicitamente programadas (GÉRON, 2019). Essa tecnologia sustenta aplicações do dia a dia, como filtros de *spam*, sistemas de recomendação e detecção de fraudes, e sua principal vantagem reside na capacidade de processar volumosos conjuntos de dados, identificando padrões complexos e correlações que escapariam a uma análise manual.

Essa mesma capacidade de mapear padrões em bases extensas viabilizou a transição do aprendizado de máquina dos domínios comerciais para as ciências da saúde. Na psiquiatria, algoritmos vêm sendo usados para identificar, em dados clínicos, os padrões associados à presença de transtornos específicos, otimizando o rastreo e o diagnóstico de condições como ansiedade e depressão (ESKANDAR, 2024; SHATTE; HUTCHINSON; TEAGUE, 2019). A

possibilidade de considerar múltiplas variáveis clínicas ao mesmo tempo e de lidar com relações não lineares entre sintomas torna essas técnicas um recurso valioso no apoio ao diagnóstico em saúde mental (SHATTE; HUTCHINSON; TEAGUE, 2019; LIU et al., 2020).

### **2.3.1 Aprendizado Supervisionado e Classificação**

Os algoritmos de aprendizado de máquina costumam ser agrupados em quatro categorias, definidas pela quantidade e pelo tipo de supervisão fornecida durante o treinamento, que são o aprendizado supervisionado, o não supervisionado, o semissupervisionado e o aprendizado por reforço (GÉRON, 2019; SHATTE; HUTCHINSON; TEAGUE, 2019).

Esta proposta de trabalho aborda especificamente as técnicas de aprendizado supervisionado voltadas para a classificação. O estudo utiliza dados previamente rotulados, derivados de diagnósticos obtidos por meio da entrevista PAPA. Ao treinar os modelos com esses exemplos de sintomas e seus respectivos diagnósticos, o algoritmo aprende as fronteiras que separam o comportamento normativo do patológico, viabilizando a predição automatizada do risco de GAD em novas triagens (CARPENTER et al., 2016).

### **2.3.2 Desafios: Desbalanceamento de Classes e Interpretabilidade**

A aplicação do aprendizado de máquina a conjuntos de dados clínicos enfrenta dois desafios centrais: a interpretabilidade dos modelos e o desbalanceamento entre as classes.

O desbalanceamento ocorre quando as classes não estão igualmente representadas no conjunto de treinamento. Em cenários médicos e de triagem psiquiátrica, é comum que os casos positivos, ou seja, as crianças com o transtorno, sejam muito menos frequentes do que os casos negativos (BROWNLEE, 2020b; CARPENTER et al., 2016). Essa dificuldade decorre do pressuposto implícito da maioria dos algoritmos clássicos, desenvolvidos sob a premissa de dados equilibrados. Em cenários de desbalanceamento, o treinamento tende a direcionar a otimização para a classe majoritária com o intuito de reduzir o erro global, comprometendo o reconhecimento da classe minoritária. Em saúde mental, esse comportamento é especialmente indesejável, já que a classe minoritária, a criança com indícios do transtorno, é justamente a de maior interesse clínico, e deixar de identificá-la representa o erro de maior custo (BROWNLEE, 2020b).

O desbalanceamento das classes afeta diretamente a escolha e a eficácia das métricas

empregadas na avaliação dos modelos. A acurácia, métrica que quantifica a proporção global de predições corretas, revela-se insuficiente e enganosa em cenários de desbalanceamento de classes. Em uma base com 85% de casos negativos, um modelo que simplesmente classificasse todas as crianças como saudáveis atingiria 85% de acurácia sem identificar um único caso real, fenômeno conhecido como paradoxo da acurácia (BROWNLEE, 2020b). Por isso, adotam-se métricas mais adequadas a dados desbalanceados, como a sensibilidade, que mede a proporção de casos positivos corretamente detectados, e o F1-Score, que combina precisão e sensibilidade em um único índice (BROWNLEE, 2020b).

O segundo desafio é a interpretabilidade. Modelos de maior complexidade, como as redes neurais profundas, alcançam alto desempenho preditivo, mas funcionam como uma "caixa preta", o que dificulta compreender quais variáveis levaram a uma determinada decisão (LIU et al., 2020). Na área da saúde, essa opacidade limita a confiança clínica, já que o profissional precisa entender o raciocínio por trás de uma predição para incorporá-la à sua decisão. Por essa razão, estudos baseados em instrumentos clínicos e amostras menores costumam priorizar algoritmos mais transparentes, como os baseados em árvores de decisão, que conseguem equilibrar bom desempenho com a capacidade de indicar o peso de cada variável na predição (ESKANDAR, 2024).

## 2.4 Trabalhos Relacionados e Lacunas da Literatura

O uso de aprendizado de máquina na psiquiatria tem crescido nos últimos anos, com aplicações voltadas ao rastreio e ao diagnóstico de transtornos mentais. Revisões da literatura mostram que algoritmos supervisionados vêm sendo empregados com sucesso para extrair padrões de bases clínicas, auxiliando na identificação de condições como ansiedade e depressão de forma mais rápida e escalável (SHATTE; HUTCHINSON; TEAGUE, 2019; LIU et al., 2020; ESKANDAR, 2024).

Na população infantil e juvenil, alguns trabalhos comprovaram a viabilidade dessas técnicas. Zhai et al. (2025) desenvolveram modelos preditivos para identificar risco de ansiedade e depressão em estudantes e observaram que o *XGBoost* obteve o melhor desempenho entre os algoritmos testados. Haque et al. (2023), por sua vez, aplicaram *Random Forest*, *Árvore de Decisão* e *Gaussian Naive Bayes* na detecção precoce de transtornos como o de ansiedade de separação, o obsessivo-compulsivo e o TDAH em crianças e adolescentes. Esses estudos indicam que modelos de classificação podem apoiar a identificação precoce de quadros psiquiátricos, permitindo intervenções antes do agravamento dos sintomas.

No rastreio da ansiedade pré-escolar a partir de instrumentos clínicos, o trabalho de Carpenter et al. (2016) é a principal referência para esta dissertação. Utilizando dados da entrevista PAPA, os autores aplicaram o algoritmo *Alternating Decision Tree* (ADTree) para identificar os itens mais preditivos do risco de GAD e de ansiedade de separação. O estudo conseguiu reduzir de forma expressiva o número de itens do questionário, usando apenas cinco nós de decisão para o GAD, com acurácia superior a 96%, e mostrou que é possível converter um instrumento diagnóstico extenso em uma pontuação contínua de risco aplicável na prática.

A Tabela 2.1 sintetiza os principais estudos discutidos, situando esta dissertação em relação à literatura.

Tabela 2.1 – Síntese comparativa entre os trabalhos correlatos da literatura e a proposta desta dissertação.

| Estudo                                | População                 | Algoritmos                          | Contribuição Principal                                                        |
|---------------------------------------|---------------------------|-------------------------------------|-------------------------------------------------------------------------------|
| Shatte, Hutchin-son and Teague (2019) | Geral                     | SVM, redes neu-rais, árvores        | Revisão ampla de aplicações de IA na saúde mental.                            |
| Eskandar (2024)                       | Geral                     | Aprendizado pro-fundo, ML           | Discussão sobre ética e interpretabilidade em psiquiatria.                    |
| Zhai et al. (2025)                    | Universitários            | XGBoost, RF, Árvore, Reg. Logística | Validação do XGBoost na predição de ansie-dade e depressão em jovens adultos. |
| Haque et al. (2023)                   | Crianças e adolescentes   | RF, Naive Bayes, Árvore             | Detecção de TOC, SAD e TDAH em crianças maiores.                              |
| Carpenter et al. (2016)               | Pré-escolares, 2 a 5 anos | ADTree                              | Estudo âncora; reduziu a PAPA a 5 nós de de-cisão para o GAD.                 |
| <b>Este trabalho</b>                  | Pré-escolares, 2 a 6 anos | XGBoost, SVM, RF, ADTree            | Comparação entre algoritmos e técnicas de ba-lanceamento na predição de GAD.  |

Esta dissertação parte da base estabelecida por Carpenter et al. (2016), mas busca ampliar a análise. Enquanto o estudo original se concentrou na árvore de decisão alternada, aqui propõe-se uma comparação entre diferentes algoritmos, com destaque para o *XGBoost*, o SVM e a *Random Forest*, avaliados junto a diversas estratégias de balanceamento de classes. A lacuna mais evidente na literatura é justamente essa combinação, poucos trabalhos tratam de ansiedade em pré-escolares com o rigor metodológico de comparar múltiplos algoritmos sob diferentes estratégias de balanceamento, priorizando métricas sensíveis ao desbalanceamento em vez da acurácia isolada.

### 3 METODOLOGIA

Este capítulo descreve os procedimentos adotados para construir e avaliar os modelos de classificação. São apresentados a base de dados utilizada, as etapas de preparação dos dados, os algoritmos testados e a estratégia experimental empregada na validação dos resultados.

#### 3.1 Visão Geral do Fluxo Metodológico

Esta pesquisa propõe uma metodologia de classificação supervisionada para estimar o risco de GAD em crianças em idade pré-escolar, a partir dos dados clínicos da entrevista PAPA. A proposta parte da modelagem de Carpenter et al. (2016), que utilizou a ADTree sobre o mesmo instrumento, e a expande em duas frentes, a incorporação de outros algoritmos, com destaque para o *XGBoost*, e a avaliação sistemática de técnicas de balanceamento de classes, ponto crítico em bases de rastreio psiquiátrico nas quais os casos positivos são minoria (BROWNLEE, 2020b).

O trabalho foi organizado em cinco etapas, ilustradas na Figura 3.1. A primeira compreende a caracterização da base de dados e o tratamento inicial das amostras (Seção 3.2). A segunda abrange o pré-processamento, com o tratamento de valores ausentes, a normalização dos atributos e a aplicação das estratégias de balanceamento (Seção 3.3). A terceira trata da seleção de características, combinando análise estatística e métodos embutidos nos próprios classificadores. A quarta corresponde à modelagem, na qual os algoritmos selecionados são treinados e comparados entre si (Seção 3.4). A quinta define a estratégia experimental de validação, incluindo a validação cruzada aninhada, o ajuste de hiperparâmetros e o experimento de Monte Carlo para auditoria de robustez (Seção 3.5).




Figura 3.1 – Visão geral do fluxo metodológico adotado, da base original ao comparativo final de modelos.

Dois focos principais orientaram o trabalho. O primeiro é a prevenção do vazamento de dados, uma vez que toda transformação, do escalonamento à reamostragem, foi ajustada apenas sobre os dados de treino de cada iteração da validação cruzada (BROWNLEE, 2020a). O segundo é a escolha da sensibilidade como métrica primária de avaliação, refletindo o custo assimétrico dos erros, já que no rastreo de ansiedade infantil deixar de identificar uma criança em risco é mais grave do que gerar um encaminhamento desnecessário (BROWNLEE, 2020b).

## 3.2 Base de Dados e Aspectos Éticos

### 3.2.1 Entrevista PAPA e Caracterização da Amostra

Os dados utilizados neste estudo derivam da entrevista PAPA, aplicada no âmbito do *PAPA Test-Retest Study* (PTRTS), conduzido em clínicas de atenção primária pediátrica da Universidade Duke (CARPENTER et al., 2016). A coleta seguiu o protocolo estruturado descrito na Seção 2.2, com entrevistadores treinados registrando os sintomas a partir de exemplos concretos relatados pelos cuidadores nos três meses anteriores.

O conjunto de dados é composto por 307 crianças com idades entre 2 e 6 anos, distribuídas em 94 participantes de 2 anos, 73 de 3 anos, 74 de 4 anos, 61 de 5 anos e 5 de 6 anos. Quanto ao sexo, 166 são meninos (54,1%) e 141 são meninas (45,9%).

Em relação ao perfil socioeconômico e familiar, 100 crianças (32,6%) vivem em situação de pobreza. Sobre a estrutura familiar, 152 crianças (49,5%) residem com ambos os pais

biológicos, 131 (42,7%) com apenas um deles e 24 (7,8%) sem nenhum pai biológico no domicílio. Quanto à convivência com irmãos, 82 crianças (26,7%) são filhas únicas, 128 (41,7%) têm um irmão, 60 (19,5%) têm dois e 37 (12,1%) têm três.

No que diz respeito à prevalência de transtornos, o GAD foi identificado em 46 crianças (15,0%). A base também registra a ocorrência de outros diagnósticos, incluindo o Transtorno de Ansiedade de Separação em 49 casos (16,0%), o Transtorno Desafiador Opositivo em 34 (11,1%), o Transtorno de Conduta em 24 (7,8%), a Fobia Social em 23 (7,5%), o TDAH em 22 (7,2%) e a Depressão em 17 casos (5,5%) (CARPENTER et al., 2016).

Cabe notar que a proporção de 15,0% de casos positivos para GAD é superior à prevalência de aproximadamente 4,7% estimada em amostras comunitárias pré-escolares (CARPENTER et al., 2016). Essa diferença reflete o desenho do PTRTS, conduzido em clínicas de atenção primária pediátrica e com enriquecimento deliberado de casos positivos, procedimento necessário para viabilizar a análise de confiabilidade teste-reteste do instrumento. Do ponto de vista da modelagem, essa característica é favorável, pois amplia o sinal da classe minoritária e aumenta a estabilidade do treinamento. Impõe, contudo, uma ressalva à generalização direta dos resultados para cenários de triagem populacional, ponto retomado na Seção 4.5.

### 3.2.2 Seleção e Codificação de Variáveis

As variáveis do conjunto de dados foram organizadas em três grupos, sendo eles as demográficas, as clínicas e as de desfecho.

As variáveis demográficas incluem o sexo da criança (*Sex*), a raça (*Race*) e a idade em anos (*Age*). A composição familiar é representada pelo número de pais biológicos no domicílio (*Number of Bio. Parents*) e pela convivência com irmãos (*Number of Siblings*). A situação financeira é indicada pela variável *Poverty Status*.

As variáveis clínicas e comportamentais quantificam as informações extraídas da entrevista. Esse grupo abrange o número de prejuízos funcionais (*Number of Impairments*, de 0 a 9), a contagem de estressores de vida do tipo B (*Number of Type B Stressors*, de 0 a 8), a frequência de birras (*Frequency Temper Tantrums*, de 0 a 9) e o humor irritável (*Frequency Irritable Mood*). Quanto à regulação fisiológica, foram incluídas as perturbações do sono (*Number of Sleep Disturbances*, de 1 a 10) e as sensibilidades sensoriais (*Number of Sensory Sensitivities*, de 0 a 4). O histórico psiquiátrico familiar (*Family History - Psychiatric Diagnosis*) e a presença de outros diagnósticos atuam como covariáveis binárias.

Algumas variáveis foram removidas na fase de pré-processamento, seja por estarem fora



do escopo, seja para evitar vazamento de dados. Foram excluídas a *Depression* isolada, o *Number of Type A Stressors*, o *Number of Physical Symptoms* e o *Family History - Substance Abuse*. Também foram descartados o peso amostral (*Sample Weight*) e as probabilidades estimadas externamente por um modelo Gamma (*GAD Probability - Gamma* e *SAD Probability - Gamma*), garantindo que os modelos aprendam apenas a partir das características clínicas brutas de cada paciente (BROWNLEE, 2020a).

### 3.2.3 Aspectos Éticos

Os dados clínicos utilizados nesta pesquisa derivam de estudos previamente aprovados pelo Comitê de Revisão Institucional do *Duke University Medical Center*. A coleta original ocorreu mediante consentimento livre e esclarecido por escrito dos pais ou responsáveis legais, após descrição completa dos procedimentos de pesquisa (CARPENTER et al., 2016).

Para a execução da modelagem computacional, a base de dados foi submetida a um processo de anonimização. Durante o pré-processamento, a variável de identificação única do paciente (*Subject*) foi permanentemente excluída da matriz analítica. Esse descarte atende às exigências de proteção à privacidade e, ao mesmo tempo, elimina uma possível fonte de vazamento de dados, evitando que os algoritmos utilizem identificadores pessoais durante o treinamento.

## 3.3 Pré-processamento e Estratégias de Balanceamento

### 3.3.1 Tratamento de Valores Ausentes

O conjunto de dados apresentou valores ausentes em apenas duas variáveis, sendo 19 registros faltantes em *Poverty Status* (6,19% dos pacientes) e 1 registro em *Social Phobia* (0,33%). Considerando as 8.289 células da base, essas 20 ausências correspondem a 0,24% de incompletude global, mas por estarem concentradas em duas variáveis acabaram afetando 20 das 307 observações, ou seja, 6,51% da amostra.

Optou-se pela exclusão completa dos registros com valores ausentes, procedimento conhecido como *listwise deletion*, resultando em um conjunto final de 287 observações. Essa escolha evita que valores imputados introduzam viés nos atributos usados como entrada para os classificadores (ZHAI et al., 2025; BROWNLEE, 2020a). Dado o percentual reduzido de per-

das, a exclusão não compromete a representatividade da amostra. Dos 20 registros excluídos, 2 apresentavam diagnóstico positivo para GAD, reduzindo os casos positivos de 46 para 44.

### 3.3.2 Normalização e Codificação de Atributos

O pré-processamento das variáveis seguiu estratégias específicas conforme a natureza de cada atributo.

As variáveis contínuas e ordinais foram normalizadas pela transformação *Min-Max*, que mapeia os valores para o intervalo  $[0, 1]$ , conforme a Equação 3.1.

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (3.1)$$

As variáveis submetidas a essa normalização foram *Age*, *Number of Impairments*, *Number of Type B Stressors*, *Frequency Temper Tantrums*, *Frequency Irritable Mood*, *Number of Sleep Disturbances* e *Number of Sensory Sensitivities*.

A variável *Number of Bio. Parents* recebeu um mapeamento proporcional, com os valores originais 0, 1 e 2 convertidos para 0, 0,5 e 1, o que preserva a ordem entre as categorias. A variável *Number of Siblings* foi binarizada, assumindo 0 para ausência de irmãos e 1 para presença de ao menos um. A variável *Sex* foi codificada por *label encoding*, mapeando M para 0 e F para 1. As variáveis já binárias na base original, como *Poverty Status*, *Race*, *Family History - Psychiatric Diagnosis* e os indicadores de comorbidades, foram mantidas sem transformação adicional.

Para evitar o vazamento de informação, o ajuste da transformação *Min-Max* foi realizado exclusivamente sobre os dados de treino de cada iteração da validação cruzada. O redimensionamento calculado foi então aplicado ao conjunto de validação correspondente, garantindo que o modelo não tivesse acesso à distribuição dos dados de teste (BROWNLEE, 2020a).

### 3.3.3 Estratégias de Balanceamento

O conjunto final apresenta distribuição desbalanceada entre as classes, com 44 casos positivos de GAD (15,3%) e 243 negativos (84,7%), o que corresponde a uma razão aproximada de 85 para 15. Como discutido na Seção 2.3.2, esse desequilíbrio tende a enviesar os algoritmos em favor da classe majoritária durante o treinamento (BROWNLEE, 2020b).

Para lidar com esse problema, foram avaliadas 12 abordagens distintas de balancea-

mento. Todas foram aplicadas exclusivamente aos dados de treinamento de cada iteração da validação cruzada, prevenindo o vazamento de dados para o conjunto de validação. As estratégias testadas foram organizadas em cinco categorias.

- Sem balanceamento, utilizado como linha de base para a comparação com os demais métodos;
- *Oversampling*, com a geração de instâncias sintéticas ou replicação da classe minoritária, avaliando SMOTE, ADASYN, Borderline-SMOTE, SMOTE-ENN e SMOTE-Tomek;
- *Undersampling*, com a remoção direcionada de instâncias da classe majoritária, avaliando *NearMiss*, *Random Undersampling* e *Instance Hardness Threshold*;
- *Ensembles* balanceados, que incorporam o balanceamento internamente em suas iterações, incluindo *EasyEnsemble*, *Balanced Random Forest* e RUSBoost;
- Ponderação de classes, com o ajuste dos pesos na função de perda do classificador para penalizar mais severamente os erros na classe minoritária, avaliada nas implementações do XGBoost e do SVM.

### 3.4 Algoritmos de Aprendizado de Máquina Avaliados

Os algoritmos foram escolhidos por lidarem bem com bases mistas, que combinam variáveis numéricas e categóricas, e por oferecerem suporte a estratégias de ajuste para classes desbalanceadas.

#### 3.4.1 Support Vector Machine

O SVM foi instanciado com a Função de Base Radial (*kernel* RBF), que projeta as características dos pacientes em um espaço de dimensão superior para lidar com a não linearidade dos dados clínicos. Para adequá-lo ao desbalanceamento da base, utilizou-se a ponderação da função de custo, penalizando os erros na classe minoritária de forma proporcional à sua raridade (BROWNLEE, 2020b).

### 3.4.2 XGBoost

O *XGBoost* foi o algoritmo principal do estudo. O método constrói árvores de decisão de forma sequencial, cada uma voltada a corrigir os erros das anteriores, e otimiza uma função objetivo com regularização (ZHAI et al., 2025). A escolha se deu por sua resistência à multicolinearidade nos dados clínicos e pela possibilidade de ajustar internamente o peso da classe positiva por meio do parâmetro `scale_pos_weight`, cujo intervalo de busca foi definido no ajuste de hiperparâmetros (Seção 3.5.1).

O *HistGradientBoosting* (HistGBM), variante que acelera o treinamento por meio de histogramas (GÉRON, 2019), foi incluído apenas na busca de hiperparâmetros, não figurando no comparativo principal.

### 3.4.3 Métodos de Ensemble

O *Random Forest* constrói várias árvores de decisão independentes, combinando *bagging* com a seleção aleatória de subconjuntos de características em cada divisão, o que reduz a variância do modelo (GÉRON, 2019). Para adequá-lo ao desbalanceamento, implementou-se a variação *Balanced Random Forest*, que força um subamostramento aleatório da classe majoritária dentro de cada iteração de treinamento (BROWNLEE, 2020b).

O *Extra Trees* segue lógica semelhante, mas sorteia de forma aleatória tanto os atributos quanto os limites de divisão em cada nó (GÉRON, 2019). Foi utilizado apenas na busca de hiperparâmetros e no cálculo de importância de atributos, não constando do comparativo final.

### 3.4.4 ADTree

A *Alternating Decision Tree* (ADTree) foi incluída como linha de base. Sua estrutura alterna nós de decisão, que são testes sobre os sintomas, com nós de predição, que carregam valores numéricos. A classificação de um paciente não depende de um único caminho até uma folha, mas da soma dos nós de predição alcançados ao longo das ramificações ativadas, resultando em um escore contínuo chamado *AD-score* (CARPENTER et al., 2016).

Sua execução ocorreu fora do ambiente Python, usando a implementação do pacote *Weka*. A inclusão do algoritmo se justifica pela necessidade de replicar a modelagem original de Carpenter et al. (2016) sobre o mesmo instrumento, estabelecendo um ponto de comparação

para os demais algoritmos.

### 3.5 Validação Experimental e Critérios de Avaliação

#### 3.5.1 Validação Cruzada Aninhada (Nested CV)

A avaliação dos modelos foi conduzida por validação cruzada estratificada de 10 partições sobre as 287 amostras, sem um conjunto de teste isolado. Essa escolha se justifica pelo tamanho reduzido da amostra, situação em que a validação cruzada oferece estimativas mais estáveis do que uma única divisão entre treino e teste (BROWNLEE, 2020b). A estratificação garante que cada partição mantenha a proporção original de aproximadamente 15% de casos positivos.

Um particionamento estratificado na proporção 80% e 20% foi usado apenas como etapa preparatória do experimento de robustez descrito na Seção 3.5.2, com o objetivo de separar um conjunto de teste a partir do qual os casos de maior incerteza pudessem ser localizados.

O ajuste dos hiperparâmetros seguiu uma estrutura de validação cruzada aninhada. A malha externa, com 10 partições, avalia o desempenho geral, enquanto a malha interna, com 5 partições, é usada exclusivamente para sintonizar as configurações, sem contaminar a avaliação final. A busca no espaço de hiperparâmetros foi feita por *GridSearchCV* no caso do SVM e por *RandomizedSearchCV* no caso do XGBoost, com número de iterações entre 50 e 500 (GÉRON, 2019).

As 12 técnicas de balanceamento foram acopladas aos classificadores dentro da malha de validação cruzada, de modo que cada combinação de algoritmo e estratégia de reamostragem fosse avaliada de forma isolada, sem contaminação entre as partições (BROWNLEE, 2020b).

#### 3.5.2 Métrica Primária, Limiares e Teste de Robustez (Monte Carlo)

O desbalanceamento da base invalida o uso da acurácia como métrica principal. Nesse cenário, um modelo que classificasse todos os pacientes como saudáveis atingiria 84,7% de acerto global sem identificar nenhum caso real. A métrica primária adotada foi, portanto, a sensibilidade, focada na detecção do maior número possível de casos positivos.

A avaliação foi complementada pelo F1-Score, pela especificidade e pelo Kappa de Cohen. Para equilibrar as penalidades entre detecção e precisão, definiu-se ainda um score

composto, calculado pela raiz quadrada do produto entre sensibilidade e F1-Score.

A calibração do limiar de decisão baseou-se na maximização do F2-Score, que assume que o custo de um falso negativo é quatro vezes superior ao de um falso positivo. Como critérios complementares, foram avaliados o índice J de Youden e a área sob a curva Precisão-Recall.

Como método complementar de auditoria, foi implementado um experimento estocástico focado nas instâncias de maior incerteza do modelo principal, chamadas de *hard samples*. Esses casos correspondem a pacientes situados na região de fronteira da decisão do classificador, onde a probabilidade de pertencer a cada classe se aproxima do limiar de 0,5, representando o cenário de maior ambiguidade diagnóstica (GÉRON, 2019).

O procedimento consistiu em executar 200 simulações de retreino, sorteando aleatoriamente a cada ciclo um subconjunto desses casos limítrofes para reincorporação à base de aprendizado. Também foi avaliada a técnica de regularização *Label Smoothing*, com  $\varepsilon = 0,1$ , como estratégia para penalizar o excesso de confiança nas predições. O objetivo foi medir o desvio padrão das métricas ao longo das repetições, verificando a estabilidade do modelo diante de casos clinicamente ambíguos (BROWNLEE, 2020b).

O número de simulações foi definido a partir de uma análise de convergência conduzida com até 500 repetições e cinco sementes independentes. Embora a magnitude do desvio padrão das métricas se estabilize já em 50 simulações, a reprodutibilidade dessa estimativa entre execuções independentes só se torna aceitável em 200, quando a amplitude do desvio padrão entre sementes cai de uma faixa de 14% a 23% para 5% a 7%. O aumento para 500 simulações reduz o erro padrão da média em menos de 0,3 ponto percentual, ao custo de 2,5 vezes mais treinamentos, sem alterar as conclusões.

### 3.6 Ferramentas e Ambiente Computacional

O desenvolvimento dos fluxos de processamento, a manipulação da base de dados e a modelagem preditiva foram executados na linguagem Python, versão 3. A escolha se apoia na consolidação dessa linguagem como principal ecossistema para aprendizado de máquina, com um conjunto de bibliotecas de código aberto voltadas à computação científica que favorece a reprodutibilidade dos experimentos (GÉRON, 2019; BROWNLEE, 2020a).

A importação e a manipulação dos dados foram feitas com as bibliotecas *Pandas* e *NumPy*. O particionamento estratificado da amostra, a otimização de hiperparâmetros, o pré-processamento, a redução de dimensionalidade e os classificadores base foram implementados por meio da biblioteca *Scikit-Learn*, que também forneceu o cálculo das métricas de avaliação,

incluindo a matriz de confusão, o  $F_\beta$ -score e a curva ROC.

Os métodos de reamostragem foram aplicados com o pacote *Imbalanced-Learn*, que reúne as técnicas de sobreamostragem, subamostragem e as abordagens combinadas descritas na Seção 3.3.3, integradas ao fluxo por meio de *pipelines*. O algoritmo de impulsionamento em gradiente utilizou a implementação nativa da biblioteca *XGBoost*, e a ADTree foi executada no pacote *Weka*.

A execução das rotinas e a validação dos modelos ocorreram integralmente em ambiente local, com os fluxos de trabalho organizados no editor *Visual Studio Code*.

## 4 RESULTADOS EXPERIMENTAIS E DISCUSSÃO

Apresenta-se neste capítulo os resultados parciais obtidos até este momento. A estrutura inicia-se com a consolidação da base de dados pós-pré-processamento, prossegue com a análise comparativa do desempenho dos algoritmos, contempla os experimentos de robustez e a identificação das variáveis mais preditivas, finalizando com a discussão dos resultados e das limitações do estudo.

### 4.1 Consolidação da Base e Pré-processamento

A base original é composta por 307 registros e 27 variáveis, totalizando 8.289 medições. A avaliação de integridade identificou dados faltantes em apenas duas variáveis, afetando 20 registros distintos ( ver Tabela 4.1). A exclusão desses registros resultou em um conjunto final de 287 amostras.

Tabela 4.1 – Quantificação de valores ausentes na base original.

| Variável                            | Registros Ausentes | Percentual da Amostra |
|-------------------------------------|--------------------|-----------------------|
| <i>Poverty Status</i>               | 19                 | 6,19%                 |
| <i>Social Phobia</i>                | 1                  | 0,33%                 |
| <b>Total de pacientes removidos</b> | <b>20</b>          | <b>6,51 %</b>         |

Após a delimitação das amostras, procedeu-se à redução do espaço dimensional dos dados. Das 27 variáveis originais, 8 foram descartadas devido à irrelevância para o escopo analítico ou por constituírem identificadores e probabilidades pré-calculadas suscetíveis a induzir vazamento de dados (data leakage). As variáveis removidas e suas justificativas constam na Tabela 4.2.

Tabela 4.2 – Relação de variáveis descartadas durante o pré-processamento.

| Variável Removida                       | Categoria     | Justificativa                                      |
|-----------------------------------------|---------------|----------------------------------------------------|
| <i>Depression</i>                       | Clínica       | Baixo volume de positivos (5,5%).                  |
| <i>Number of Type A Stressors</i>       | Clínica       | Distribuição problemática, sem valor zero na base. |
| <i>Number of Physical Symptoms</i>      | Clínica       | Fora do escopo preditivo.                          |
| <i>Family History - Substance Abuse</i> | Clínica       | Fora do escopo preditivo.                          |
| <i>Subject</i>                          | Identificador | Identificador único, sem valor preditivo.          |
| <i>GAD Probability - Gamma</i>          | Risco Externo | Risco pré-calculado, induz vazamento de dados.     |
| <i>SAD Probability - Gamma</i>          | Risco Externo | Risco pré-calculado, induz vazamento de dados.     |
| <i>Sample Weight</i>                    | Estatística   | Peso amostral externo à condição do paciente.      |



A matriz analítica ficou reduzida a 19 colunas. Como a modelagem se concentrou no GAD, a variável de diagnóstico do SAD foi removida do vetor de entrada, resultando em 18 colunas ativas, das quais 17 são variáveis preditoras e uma é a variável-alvo.

O mapeamento da variável-alvo sobre os 287 pacientes restantes confirmou a proporção assimétrica esperada em dados de rastreo. Conforme a Tabela 4.3, o GAD registrou 44 casos positivos contra 243 negativos, o que corresponde a uma razão aproximada de 85 para 15.

Tabela 4.3 – Distribuição final da classe alvo após o pré-processamento.

| <b>Transtorno</b> | <b>Positivos</b> | <b>Negativos</b> | <b>Positivos (%)</b> |
|-------------------|------------------|------------------|----------------------|
| GAD               | 44               | 243              | 15,3%                |

Esse número confirma na prática o que foi antecipado na Seção 3.5.2. Com essa distribuição, um classificador que apontasse todos os pacientes como saudáveis atingiria 84,7% de acurácia sem identificar um único caso, o que reforça a escolha da sensibilidade como métrica de referência na avaliação dos modelos.

## 4.2 Desempenho dos Modelos e Comparativo de Algoritmos

### 4.2.1 Hiperparâmetros e Calibração do Limiar de Decisão

A Tabela 4.4 apresenta os hiperparâmetros selecionados pela busca em grade para cada combinação de algoritmo e técnica de balanceamento. A busca foi conduzida via validação cruzada aninhada com dez partições externas e cinco internas, otimizando F1-Score.

Tabela 4.4 – Hiperparâmetros selecionados pela busca em grade, por algoritmo e técnica de balanceamento.

| <b>Modelo</b> | <b>Técnica</b>    | <i>learning_rate</i> | <i>max_depth</i> | <i>n_estimators</i> | <i>subsample</i> | <i>C / gamma</i>     |
|---------------|-------------------|----------------------|------------------|---------------------|------------------|----------------------|
| XGBoost       | Sem balanceamento | 0,20                 | 3                | 50                  | 0,8              | –                    |
| XGBoost       | Class Weighting   | 0,10                 | 3                | 50                  | 1,0              | –                    |
| XGBoost       | SMOTE             | 0,10                 | 3                | 100                 | 1,0              | –                    |
| XGBoost       | Undersampling     | 0,10                 | 3                | 50                  | 0,8              | –                    |
| SVM           | Sem balanceamento | –                    | –                | –                   | –                | C=100; $\gamma=0,01$ |
| SVM           | Class Weighting   | –                    | –                | –                   | –                | C=1; $\gamma=0,001$  |
| SVM           | SMOTE             | –                    | –                | –                   | –                | C=1; $\gamma=0,001$  |
| SVM           | Undersampling     | –                    | –                | –                   | –                | C=1; $\gamma=0,01$   |

Vale ressaltar que os hiperparâmetros utilizados correspondem à moda das configurações escolhidas nas dez partições externas da validação cruzada, refletindo a configuração de

maior consenso ao longo da busca. Para o XGBoost, observa-se convergência para árvores rasas ( $max\_depth = 3$ ) e ensembles compactos (50 a 100 estimadores), padrão coerente com o tamanho reduzido da amostra, no qual árvores mais profundas tenderiam a superajuste. Para o SVM, a convergência para  $C = 1$  e  $\gamma = 0,001$  nas configurações balanceadas indica preferência por fronteiras de decisão mais suaves quando a distribuição das classes é ajustada.

A calibração do limiar de decisão foi avaliada para o XGBoost com SMOTE, configuração de maior AUC entre as combinações analisadas na Seção 4.2.2. A Tabela 4.5 compara três critérios de escolha do limiar aplicados sobre a mesma curva de probabilidades preditas.

Tabela 4.5 – Comparativo de critérios de calibração do limiar de decisão, XGBoost com SMOTE. O limiar  $t$  varia por critério, enquanto as métricas discriminativas subjacentes permanecem constantes.

| <b>Critério</b> | <b>Limiar</b> | <b>Sensibilidade</b> | <b>Especificidade</b> | <b>F1-Score</b> | <b>Kappa</b> |
|-----------------|---------------|----------------------|-----------------------|-----------------|--------------|
| Padrão          | 0,50          | 34,1%                | 94,2%                 | 41,1%           | 0,329        |
| J de Youden     | 0,22          | 52,3%                | 86,8%                 | 46,5%           | 0,355        |
| F1 Máximo       | 0,41          | 43,2%                | 93,0%                 | 47,5%           | 0,391        |

O critério de Youden elevou a detecção de 15 para 23 crianças com GAD entre os 44 casos positivos, ao custo de 18 falsos alarmes adicionais, resultando em uma razão de 2,2 falsos positivos por novo caso detectado. Já o critério de F1 máximo ofereceu o melhor Kappa da comparação, 0,391, preservando especificidade próxima à configuração padrão. A diferença entre esse valor e o Kappa de 0,311 reportado para o BorderlineSMOTE na Tabela 4.7 decorre exclusivamente da calibração de limiar, não de uma superioridade intrínseca do SMOTE, ponto já discutido na Seção 4.2.2.

A comparação entre os três critérios ilustra que a calibração do limiar de decisão é uma etapa crítica em cenários de classificação desbalanceada. O limiar padrão de 0,50, herdado da suposição de classes equilibradas, subutiliza a capacidade discriminativa do modelo, o que se reflete na baixa sensibilidade e no Kappa aquém do que a AUC de 0,751 permitiria. A escolha do critério de calibração, portanto, deve ser guiada pelo objetivo clínico da triagem, considerando o custo relativo dos falsos negativos e dos falsos positivos.

#### 4.2.2 Métricas Discriminativas (Kappa, Sensibilidade, AUC/ROC)

A Tabela 4.6 apresenta o desempenho de cada algoritmo sob quatro estratégias de balanceamento. As configurações exibidas representam os perfis mais distintos entre as 12 técnicas

avaliadas.

Tabela 4.6 – Desempenho individual dos modelos para o GAD, validação cruzada estratificada de 10 partições, com limiar de decisão padrão ( $t = 0,50$ ).\*

| Modelo  | Técnica           | Acurácia | Sensibilidade | F1    | Kappa |
|---------|-------------------|----------|---------------|-------|-------|
| XGBoost | Sem balanceamento | 85,7%    | 24,0%         | 33,5% | 0,270 |
| XGBoost | Class Weighting   | 83,6%    | 38,0%         | 41,1% | 0,319 |
| XGBoost | SMOTE             | 83,6%    | 36,0%         | 39,2% | 0,304 |
| XGBoost | Undersampling     | 64,9%    | 67,0%         | 37,4% | 0,195 |
| SVM     | Sem balanceamento | 84,7%    | 0,0%          | 0,0%  | 0,000 |
| SVM     | Class Weighting   | 77,0%    | 39,0%         | 33,9% | 0,210 |
| SVM     | SMOTE             | 75,7%    | 22,5%         | 22,5% | 0,084 |
| SVM     | Undersampling     | 66,6%    | 65,0%         | 36,3% | 0,189 |
| ADTree  | Sem balanceamento | 82,3%    | 11,5%         | 13,8% | 0,081 |
| ADTree  | Class Weighting   | 64,1%    | 59,0%         | 33,9% | 0,153 |
| ADTree  | SMOTE             | 58,6%    | 73,0%         | 35,4% | 0,157 |
| ADTree  | Undersampling     | 65,9%    | 56,0%         | 34,4% | 0,166 |

\* Os valores de sensibilidade, F1 e Kappa correspondem à média das métricas calculadas partição a partição, procedimento necessário para o cálculo dos intervalos de confiança. As matrizes de confusão apresentam a soma acumulada das 10 partições, o que gera diferenças de até 1,1 ponto percentual em relação aos valores aqui reportados.

O XGBoost apresentou o melhor desempenho em praticamente todas as configurações. Mesmo sem qualquer técnica de balanceamento, atingiu Kappa de 0,270, patamar que nenhum dos demais algoritmos alcançou nessa condição. A adoção de *Class Weighting* elevou a sensibilidade para 38,0% e o Kappa para 0,319, enquanto o SMOTE gerou um perfil similar em concordância, com Kappa de 0,304 e sensibilidade de 36,0%.

O SVM revelou uma limitação importante. Sem balanceamento, o modelo classificou todas as amostras como negativas, atingindo sensibilidade zero e Kappa nulo. A acurácia de 84,7% reflete apenas a classe majoritária, e o resultado mostra que o algoritmo, em sua configuração padrão, aprendeu somente a distribuição dominante, sendo inviável para triagem. A introdução de *Class Weighting* corrigiu parcialmente essa tendência, elevando a sensibilidade para 39,0%.

A ADTree apresentou comportamento instável entre as configurações. Com SMOTE, atingiu 73,0% de sensibilidade, mas com especificidade de apenas 55,9% e Kappa de 0,157, indicando que boa parte das classificações positivas eram falsos alarmes. A configuração com *undersampling* foi a mais equilibrada para esse algoritmo, ainda assim inferior ao XGBoost e ao SVM.

A Tabela 4.7 consolida o melhor Kappa atingido por cada algoritmo, junto à técnica de balanceamento responsável pelo resultado.

Tabela 4.7 – Melhor coeficiente Kappa por algoritmo, com limiar de decisão padrão ( $t = 0,50$ ).

| <b>Algoritmo</b> | <b>Melhor Kappa</b> | <b>Técnica de Balanceamento</b> |
|------------------|---------------------|---------------------------------|
| XGBoost          | 0,311               | BorderlineSMOTE                 |
| SVM              | 0,210               | Class Weighting                 |
| ADTree           | 0,166               | Undersampling                   |

Cabe uma observação sobre a comparação com a Tabela 4.5. O Kappa de 0,391 ali reportado para o XGBoost com SMOTE, superior aos 0,311 do BorderlineSMOTE, foi obtido com o limiar de decisão calibrado por máximo F1-Score ( $t = 0,41$ ), enquanto os valores desta tabela adotam o limiar padrão ( $t = 0,50$ ) para todos os algoritmos, garantindo comparabilidade entre as estratégias de balanceamento. A calibração de limiar altera o ponto de operação do classificador sem modificar sua capacidade discriminativa subjacente, medida pela AUC, o que explica a diferença observada entre as duas tabelas.

Vale registrar que a configuração com Focal Loss atingiu Kappa marginalmente superior ao BorderlineSMOTE, com 0,326 contra 0,311, e sensibilidade de 59,5%. A diferença, contudo, está bem abaixo do desvio padrão observado em ambas as configurações, na ordem de 0,10 a 0,18 pontos, não permitindo afirmar superioridade estatística. Optou-se por manter o BorderlineSMOTE como configuração de referência ao longo desta análise pela sua maior especificidade (93,4% contra 81,5% do Focal Loss), característica desejável em cenários de apoio à decisão diagnóstica em que falsos positivos implicam encaminhamentos desnecessários. As duas configurações são reportadas em conjunto na análise de trade-off adiante.

Estabelecido o XGBoost como algoritmo de referência, a escolha da técnica de balanceamento revelou-se um compromisso entre concordância e capacidade de detecção, ilustrado na Tabela 4.8. Estratégias voltadas ao equilíbrio maximizam o Kappa preservando alta especificidade, enquanto estratégias mais agressivas de reamostragem elevam a sensibilidade ao custo de mais falsos positivos.

Tabela 4.8 – Compromisso entre concordância e detecção no XGBoost, com limiar de decisão padrão ( $t = 0,50$ ).

| <b>Estratégia</b>   | <b>Acurácia</b> | <b>Sensibilidade</b> | <b>F1-Score</b> | <b>Especificidade</b> | <b>Kappa</b> |
|---------------------|-----------------|----------------------|-----------------|-----------------------|--------------|
| BorderlineSMOTE     | 84,3%           | 34,5%                | 39,3%           | 93,4%                 | 0,311        |
| Focal Loss          | 78,1%           | 59,5%                | 45,2%           | 81,5%                 | 0,326        |
| GridSearch (Recall) | 68,7%           | 73,5%                | 42,6%           | 68,0%                 | 0,265        |
| EasyEnsemble        | 66,2%           | 68,5%                | 38,9%           | 65,9%                 | 0,217        |

A Tabela 4.8 e a Figura 4.1 revelam um espectro claro de configurações, cada uma adequada a um objetivo clínico distinto. O BorderlineSMOTE opera no extremo conservador, com a maior especificidade (93,4%) mas sensibilidade limitada (34,5%), sendo indicado para cenários em que o custo de encaminhamentos desnecessários é elevado. O Focal Loss ocupa uma posição intermediária, com o melhor Kappa (0,326) e sensibilidade quase dobrada em relação ao BorderlineSMOTE. Na outra ponta, o GridSearch otimizado para recall atinge 73,5% de sensibilidade, ao custo de queda expressiva na especificidade (68,0%), sendo mais adequado a rastreio populacional em larga escala.




Figura 4.1 – Espectro de trade-off entre sensibilidade e especificidade nas quatro configurações do XGBoost. As configurações se distribuem em um contínuo, do extremo conservador (*BorderlineSMOTE*) ao extremo de máxima detecção (*GridSearch* otimizado para *recall*).

Não existe, portanto, um modelo universalmente superior, mas sim arquiteturas cujos desempenhos se otimizam conforme os objetivos clínicos estabelecidos.

Para o suporte à decisão diagnóstica, a combinação do algoritmo XGBoost com a técnica Borderline-SMOTE consolida-se como a escolha mais adequada. Para rastreio populacional em larga escala, onde a prioridade é não deixar casos sem identificação, a configuração com GridSearch otimizado para recall se mostra mais adequada, ainda que com menor especificidade.

Para avaliar a capacidade discriminativa por meio da área sob a curva ROC (AUC-ROC), os algoritmos foram comparados sob uma única técnica de balanceamento — o SMOTE —, isolando-se, assim, o efeito intrínseco de cada classificador. O XGBoost com SMOTE registrou AUC média de 0,751 (IC 95% de  $\pm 0,103$ ), contra 0,678 do SVM na mesma técnica (IC 95% de  $\pm 0,069$ ). Vale notar que o SMOTE representou a configuração de menor AUC para o SVM, cuja melhor discriminação foi obtida com *undersampling*, chegando a 0,725. Mesmo comparando cada algoritmo em sua melhor configuração, o XGBoost mantém a maior discriminação,

atingindo AUC de 0,763 ( $\pm 0,087$ ) na configuração com *BorderlineSMOTE*, aquela declarada como modelo principal desta análise, conforme ilustra a Figura 4.2.




Figura 4.2 – Curvas ROC comparativas para as três configurações mais representativas: XGBoost com *BorderlineSMOTE* (AUC 0,763), XGBoost com SMOTE (AUC 0,751) e SVM com SMOTE (AUC 0,678). A linha diagonal representa um classificador aleatório.

Cabe, contudo, uma ressalva metodológica: os intervalos de confiança dessas configurações apresentam sobreposição expressiva. Consequentemente, a métrica de AUC isolada não fornece subsídios suficientes para inferir uma superioridade estatisticamente significativa do XGBoost. O teste  $t$  pareado sobre as dez partições não rejeitou a hipótese de igualdade entre os dois algoritmos, com  $t = 1,19$  e intervalo de confiança da diferença contendo o zero, resultado confirmado pelo teste não paramétrico de Wilcoxon. A conclusão de superioridade se apoia, portanto, nas métricas em que a separação entre os modelos é consistente, em particular o Kappa e o F1-Score, e não na AUC.

Por fim, nenhuma das combinações avaliadas atingiu concordância moderada, ou seja, Kappa acima de 0,40, segundo a escala de Landis e Koch (LANDIS; KOCH, 1977). Os melhores resultados permaneceram na faixa de concordância razoável, limitação atribuída principalmente ao número reduzido de casos positivos, que resulta em intervalos de confiança amplos, sobretudo na sensibilidade.

#### 4.2.3 Validação de Robustez (Simulação de Monte Carlo em Hard Samples)

O experimento de robustez foi conduzido sobre o conjunto de teste de 58 amostras, correspondente a 20% das 287 observações separadas previamente por particionamento estratificado ( $test\_size = 0,20$ ,  $random\_state = 42$ ). Desse conjunto, foram identificados os 20 casos em que o modelo apresentou menor margem de confiança, com probabilidade média de 0,484, praticamente sobre o limiar de decisão. Desses 20 casos, 5 eram positivos reais e 15 negativos reais. O modelo base, treinado sobre o conjunto de treino original de 229 amostras e aplicado especificamente sobre esses 20 hard samples, acertou apenas 9 (2 dos 5 positivos e 7 dos 15 negativos), o que confirma a dificuldade de classificação nessa região de fronteira.

Cada uma das 200 simulações seguiu o mesmo protocolo. Primeiro, 15 dos 20 casos difíceis foram sorteados aleatoriamente e reincorporados ao conjunto de treino para retreinamento do modelo. Em seguida, a avaliação foi realizada sobre 43 amostras, formadas pela união de dois grupos: as 38 amostras remanescentes do conjunto de teste original, após a exclusão dos 20 hard samples, e os 5 casos difíceis não sorteados naquela iteração. Essa composição mede simultaneamente o desempenho do modelo em amostras representativas do teste geral e sua capacidade de generalização para casos limítrofes não vistos durante o retreinamento, garantindo que os conjuntos de treino e avaliação permaneçam disjuntos em toda simulação.

Uma primeira versão do experimento apresentava uma falha metodológica que vale detalhar, por ilustrar um cuidado central deste trabalho. Nessa versão, os 15 casos sorteados a cada simulação eram inseridos no conjunto de treino, mas a avaliação subsequente incidia sobre a totalidade dos 20 casos difíceis. O modelo era, portanto, testado sobre os mesmos exemplos que acabara de usar no treinamento, configurando vazamento de dados. A estimativa resultante era artificialmente otimista, já que o modelo apenas reproduzia rótulos memorizados.

A correção tornou os conjuntos de treino e avaliação disjuntos, conforme o protocolo descrito acima. A Tabela 4.9 mostra o impacto dessa correção.

Tabela 4.9 – Impacto da correção do vazamento de dados no experimento de Monte Carlo.

| Métrica        | Com vazamento     | Após a correção   |
|----------------|-------------------|-------------------|
| Acurácia       | 93,20% $\pm$ 0,63 | 82,88% $\pm$ 0,29 |
| Sensibilidade  | 84,30% $\pm$ 2,13 | 9,13% $\pm$ 1,39  |
| Especificidade | 96,17% $\pm$ 0,57 | 93,18% $\pm$ 0,22 |
| F1-Score       | 85,67% $\pm$ 1,40 | 11,23% $\pm$ 1,69 |
| Kappa          | 0,81 $\pm$ 0,02   | 0,03 $\pm$ 0,02   |

A diferença é expressiva. O Kappa cai de 0,81 para 0,03 quando a avaliação deixa de incidir sobre os casos usados no retreino, o que evidencia o quanto uma sobreposição entre treino e teste pode distorcer os resultados.

Os resultados finais, já com a correção aplicada, constam na Tabela 4.10. A coluna Base reporta o desempenho do modelo original, sem reincorporação de hard samples, avaliado sobre as 38 amostras do teste honesto (teste original excluídos os 20 hard samples). Já as colunas Sem Smoothing e Com Smoothing reportam a média das 200 simulações, avaliadas sobre 43 amostras cada (38 do teste honesto mais 5 hard samples remanescentes por iteração).

Tabela 4.10 – Resultados da simulação de Monte Carlo, 200 simulações com sorteio de 15 dos 20 casos difíceis e avaliação sobre 43 amostras (38 do teste honesto mais 5 hard samples remanescentes por iteração).

| <b>Métrica</b> | <b>Base</b> | <b>Sem <i>Smoothing</i></b> | <b>Com <i>Smoothing</i></b> |
|----------------|-------------|-----------------------------|-----------------------------|
| Acurácia       | 84,21%      | 82,88% $\pm$ 2,09%          | 82,93% $\pm$ 2,23%          |
| Sensibilidade  | 0,00%       | 9,13% $\pm$ 9,96%           | 11,01% $\pm$ 10,16%         |
| Especificidade | 94,12%      | 93,18% $\pm$ 1,58%          | 92,96% $\pm$ 1,89%          |
| F1-Score       | 0,00%       | 11,23% $\pm$ 12,15%         | 13,52% $\pm$ 12,35%         |
| Kappa          | −0,08       | 0,0264 $\pm$ 0,1233         | 0,0478 $\pm$ 0,1279         |

Os números confirmam que os casos de fronteira permanecem difíceis. Mesmo sob reamostragem repetida, o modelo não recuperou capacidade discriminativa sobre esse subconjunto, o que indica que a limitação vem da escassez de sinal na classe positiva, e não de instabilidade no procedimento de treino. O *Label Smoothing* produziu ganho marginal, elevando a sensibilidade de 9,13% para 11,01%, dentro da margem de variação do experimento.

Esse achado delimita o teto de desempenho alcançável com a amostra disponível e sustenta a recomendação dos modelos como ferramentas auxiliares de triagem, e não como substitutos da avaliação clínica.

### 4.3 Importância das Características Preditivas

A extração da importância dos atributos permite identificar quais variáveis clínicas mais pesaram nas decisões do modelo. A Tabela 4.11 e a Figura ?? apresentam os cinco atributos de maior peso preditivo segundo o XGBoost.

O atributo de maior peso é o número de prejuízos funcionais, medida que quantifica quantos domínios da vida da criança são afetados pelos sintomas. Esse resultado tem coerência clínica direta, já que o prejuízo funcional é justamente o critério que separa o medo normativo



Tabela 4.11 – Cinco atributos de maior importância preditiva para o GAD segundo o XGBoost.

| Posição | Atributo                                            | Importância |
|---------|-----------------------------------------------------|-------------|
| 1º      | <i>Number of Impairments</i> (prejuízos funcionais) | 0,163       |
| 2º      | <i>Race</i> (raça)                                  | 0,112       |
| 3º      | Transtorno Desafiador Opositivo                     | 0,083       |
| 4º      | Fobia Social                                        | 0,080       |
| 5º      | TDAH                                                | 0,078       |

do quadro patológico, conforme discutido na Seção 2.1. O modelo, ao atribuir maior peso a essa variável, converge para o mesmo princípio que orienta o diagnóstico clínico.

Chama atenção a presença de três comorbidades entre os cinco atributos mais relevantes. O Transtorno Desafiador Opositivo, a Fobia Social e o TDAH aparecem como preditores do GAD, o que reflete a alta taxa de comorbidade observada na população pré-escolar e sugere que o modelo captura padrões de sobreposição diagnóstica em vez de sinais isolados do transtorno.

A variável *Race* na segunda posição merece uma qualificação importante. Sua relevância preditiva provavelmente reflete disparidades socioeconômicas e de acesso a serviços de saúde mental correlacionadas à variável racial na amostra norte-americana utilizada, e não uma relação causal com o transtorno (CARPENTER et al., 2016). Esse ponto reforça a necessidade de validação externa em amostras culturalmente distintas, discutida na Seção 4.5.

Tabela 4.12 – Nós de decisão selecionados pela ADTree para o GAD em Carpenter et al. (2016).

| Nó | Sintoma da entrevista PAPA                             |
|----|--------------------------------------------------------|
| 1  | Medo ou ansiedade intrusiva e incontrolável            |
| 2  | Preocupação constante e persistente                    |
| 3  | Sentir-se assustado sem motivo aparente                |
| 4  | Dificuldade de atenção em atividades de interesse      |
| 5  | Tensão muscular visível durante episódios de ansiedade |

O contraste com o estudo de referência é notável. Carpenter et al. (2016) identificaram, por meio da ADTree, cinco sintomas isolados como nós de decisão para o GAD, conforme a Tabela 4.12.

Enquanto o modelo original apoia-se em sintomas específicos da ansiedade, o XGBoost priorizou medidas agregadas de gravidade e comorbidades. Essa diferença decorre da natureza dos dados disponíveis, uma vez que o conjunto utilizado nesta dissertação não contém os itens individuais da entrevista PAPA, mas sim variáveis já consolidadas. Trata-se de uma limitação da base, não de uma divergência conceitual entre as abordagens, e será retomada na Seção 4.5.

#### 4.4 Discussão dos Achados e Impacto Clínico

Os resultados demonstram o XGBoost como o algoritmo que melhor apresentou rastreio do GAD nesta base. Sua vantagem sobre o SVM e a ADTree sugere que, neste problema, a capacidade de modelar interações entre poucas variáveis pesa mais do que a fronteira de decisão construída por um hiperplano ou por uma árvore isolada.

A escolha da técnica de balanceamento não define um vencedor absoluto, mas um compromisso atrelado ao objetivo clínico. O *BorderlineSMOTE* maximiza a concordância e preserva a especificidade, sendo preferível quando um falso positivo implica encaminhamento desnecessário. Já a configuração com *GridSearch* otimizado para *recall* eleva a sensibilidade a 73,5%, mostrando-se mais adequada ao rastreio em larga escala, no qual não detectar um caso real é o erro mais grave. Essa distinção é relevante porque desloca a decisão do campo estatístico para o clínico, já que a configuração adequada depende do contexto de uso e dos recursos disponíveis para avaliação especializada.

O achado de maior peso, contudo, é o teto de desempenho imposto pela amostra. O experimento de Monte Carlo mostrou que os casos de fronteira permanecem difíceis mesmo sob reamostragem repetida, e a correção do vazamento de dados evidenciou o quanto uma falha metodológica sutil pode produzir resultados enganosos. A limitação decorre da escassez de sinal na classe positiva, não da instabilidade do procedimento de treino. Como nenhuma configuração ultrapassou a concordância razoável na escala de Landis e Koch, os modelos devem ser entendidos como ferramentas auxiliares de triagem, capazes de priorizar crianças em risco, mas não de substituir a avaliação clínica.

O contraponto com Carpenter et al. (2016) revela uma divergência importante quanto à leitura das métricas. O estudo original reportou acurácia superior a 96% para o GAD, número que, isolado, sugere desempenho quase perfeito. A replicação conduzida aqui, submetida ao conjunto de teste com a proporção real de 85 para 15, mostrou que a acurácia elevada é em boa parte um artefato da classe majoritária. Sem estratégias de reamostragem, tanto o SVM quanto o XGBoost atingiram acurácias acima de 84% com sensibilidade próxima de zero, ou seja, sem identificar praticamente nenhum caso. Esse resultado não invalida o trabalho de referência, mas indica que a avaliação de modelos em bases de rastreio exige métricas sensíveis ao desbalanceamento.

Do ponto de vista prático, a eficiência computacional dos modelos baseados em árvores favorece sua aplicação em ambiente clínico. Uma vez treinado, o XGBoost exige custo de processamento reduzido para avaliar novos pacientes, já que a predição se resume a percorrer

uma sequência de testes lógicos. Isso dispensa infraestrutura dedicada ou processamento em nuvem, permitindo que o modelo seja executado localmente em computadores comuns de clínicas pediátricas ou em sistemas de prontuário eletrônico. É uma diferença relevante em relação a arquiteturas de aprendizado profundo, cujo custo de implantação costuma ser proibitivo nesses contextos.

O impacto clínico esperado, portanto, não está em substituir o diagnóstico, mas em reduzir o tempo entre a suspeita e o encaminhamento. Em um cenário no qual a entrevista completa consome cerca de cem minutos e exige treinamento especializado, um instrumento capaz de sinalizar risco a partir de poucas variáveis já disponíveis no atendimento pode ampliar o alcance da triagem, sobretudo em serviços com alta demanda e poucos profissionais habilitados.

#### **4.5 Limitações do Estudo**

A principal limitação deste trabalho é o tamanho da amostra. O conjunto de 287 pacientes, com apenas 44 casos positivos, resulta em cerca de quatro a cinco casos positivos por partição de teste na validação cruzada. Nesse cenário, cada acerto ou erro individual desloca a sensibilidade em aproximadamente vinte pontos percentuais, o que explica os intervalos de confiança amplos observados ao longo dos experimentos. Essa instabilidade estabelece um teto para o desempenho alcançável e impede que os modelos atinjam faixas de concordância mais altas.

Uma segunda limitação diz respeito à composição das variáveis disponíveis. A base utilizada não contém os itens individuais da entrevista PAPA, mas sim medidas já consolidadas, como contagens de sintomas e indicadores de comorbidade. Isso impede a replicação exata da abordagem de Carpenter et al. (2016), que operou sobre os itens brutos, e restringe a possibilidade de propor um instrumento de triagem reduzido baseado em perguntas específicas, objetivo que motivou a análise de importância de atributos.

Os dados também derivam de um único centro clínico e de um contexto geográfico específico. A ausência de validação externa em bases independentes impede afirmar que o desempenho observado se mantenha em populações com perfis socioeconômicos, raciais e culturais distintos. Essa restrição é particularmente relevante diante do peso preditivo atribuído à variável racial, discutido na Seção 4.3.

Soma-se a isso a proporção de casos positivos na amostra, discutida na Seção 3.2.1. Os 15,0% de crianças com GAD no PTRTS superam a prevalência comunitária estimada em cerca de 4,7% (CARPENTER et al., 2016), resultado do enriquecimento deliberado característico de

estudos de teste-reteste. Sensibilidade e especificidade, por serem métricas condicionadas à classe verdadeira, não se alteram com a prevalência, mas o valor preditivo positivo tende a cair quando o modelo é aplicado a populações com menor incidência do transtorno. Uma validação prospectiva em atenção primária não enriquecida seria necessária para calibrar essa expectativa e estimar a taxa real de falsos alarmes em uso clínico rotineiro.

Por fim, o modelo opera sobre uma análise transversal, baseada em relato parental estruturado em um único momento. Ele mapeia associações entre características clínicas e o desfecho, sem estabelecer relações causais ou acompanhar a trajetória da criança ao longo do tempo. O sistema resultante é, portanto, um instrumento de triagem probabilística, voltado a acelerar o rastreio e orientar a alocação de recursos, sem escopo para substituir a avaliação e o julgamento do profissional de saúde mental.

## 5 CONCLUSÃO E PRÓXIMOS PASSOS

### 5.1 Conclusões

Este trabalho investigou a aplicação de algoritmos de aprendizado de máquina na predição do risco de GAD em crianças em idade pré-escolar, a partir de dados da entrevista PAPA. Entre os algoritmos avaliados, o XGBoost apresentou o melhor desempenho, atingindo Kappa de 0,372 com a técnica *BorderlineSMOTE*, superando de forma consistente o SVM e a ADTree, algoritmo utilizado no estudo de referência de Carpenter et al. (2016).

Os resultados confirmaram que o desbalanceamento de classes é um obstáculo central no rastreamento de transtornos psiquiátricos pouco prevalentes. Sem estratégias de balanceamento, modelos capazes de atingir mais de 84% de acurácia revelaram sensibilidade próxima de zero, incapazes de identificar praticamente qualquer caso positivo. Esse achado reforça que a acurácia isolada não é uma métrica adequada para avaliar classificadores em bases de rastreamento clínico, e que a escolha de métricas sensíveis ao desbalanceamento, como o Kappa e a sensibilidade, é indispensável para uma leitura honesta do desempenho.

O experimento de robustez por simulação de Monte Carlo delimitou um teto de desempenho para a amostra disponível. Os casos de fronteira, aqueles em que o modelo apresenta maior incerteza, permaneceram difíceis mesmo sob reamostragem repetida, o que indica que a limitação decorre da escassez de sinal na classe positiva, e não de instabilidade no procedimento de treino. Como nenhuma configuração testada atingiu concordância moderada segundo a escala de Landis e Koch, conclui-se que os modelos desenvolvidos devem ser entendidos como ferramentas auxiliares de triagem, capazes de priorizar crianças em risco para avaliação especializada, e não como substitutos do diagnóstico clínico.

### 5.2 Principais Contribuições

A principal contribuição deste estudo, até o momento, reside no avanço metodológico proporcionado em relação a abordagem proposta por Carpenter et al. (2016), substituindo a ADTree, por algoritmos de maior capacidade preditiva e avaliando de forma sistemática doze técnicas distintas de balanceamento de classes. Essa comparação evidenciou que a escolha da técnica de reamostragem excede o âmbito estritamente estatístico, constituindo um compromisso clínico decisivo entre sensibilidade e especificidade, que deve ser ajustado conforme o contexto de uso do modelo, seja como apoio à decisão diagnóstica ou como rastreamento populacio-

nal em larga escala.

Adicionalmente, destaca-se como contribuição a identificação de um vazamento de dados (data leakage) em uma versão preliminar do teste de robustez. A devida correção do protocolo evidenciou a suscetibilidade dos modelos à inflação artificial de métricas diante de falhas metodológicas sutis. Isso reforça a importância do rigor metodológico na condução de experimentos com aprendizado de máquina em contextos clínicos, nos quais estimativas otimistas podem ter consequências práticas na tomada de decisão em saúde.

Por fim, a análise de importância de atributos revelou que o número de prejuízos funcionais é o preditor mais relevante do GAD nesta base, resultado que converge com o próprio critério clínico usado para diferenciar o medo normativo do quadro patológico. A presença de comorbidades entre os atributos mais relevantes sugere ainda que o modelo captura padrões de sobreposição diagnóstica, uma perspectiva complementar à abordagem de sintomas isolados adotada no estudo de referência.

### 5.3 Trabalhos Futuros

Duas frentes de continuidade se destacam a partir dos resultados obtidos. A primeira é a extensão da modelagem ao Transtorno de Ansiedade de Separação (SAD), que não foi tratado até então, mas que apresenta prevalência semelhante ao GAD na base utilizada e figurou entre as comorbidades mais relevantes na análise de importância de atributos. A aplicação deste mesmo pipeline metodológico, mediante a reotimização independente de hiperparâmetros e do limiar de decisão, permitirá avaliar se os achados obtidos se generalizam para outros transtornos de ansiedade na primeira infância ou se demandam estratégias específicas.

A segunda frente será a ampliação da base de dados. Além do PTRTS utilizado nesta dissertação, Carpenter et al. (2016) empregaram uma segunda base de dados independente, coletada no mesmo contexto clínico da Duke University, o *Preschool Anxiety Study* (PAS), com amostra substancialmente maior, de 917 crianças. O tamanho reduzido do PTRTS, com apenas 44 casos positivos de GAD, foi a principal limitação apontada na Seção 4.5 e o fator que mais restringiu a estabilidade das métricas ao longo dos experimentos. A aplicação do mesmo pipeline metodológico à base PAS permitiria treinar os modelos sobre um volume amostral maior, com potencial para reduzir os intervalos de confiança observados e viabilizar a validação cruzada dos modelos treinados em uma base sobre a outra, aproximando este trabalho de um cenário de validação externa.

## CRONOGRAMA

A Tabela 5.1 apresenta o cronograma previsto para a conclusão das atividades relacionadas a esta dissertação, incluindo a modelagem do Transtorno de Ansiedade de Separação (SAD), a escrita de um artigo científico e a finalização do texto da dissertação.

Tabela 5.1 – Cronograma de atividades previstas até dezembro de 2026.

| <b>Atividade</b>                          | <b>Ago</b> | <b>Set</b> | <b>Out</b> | <b>Nov</b> | <b>Dez</b> |
|-------------------------------------------|------------|------------|------------|------------|------------|
| Modelagem e validação do SAD              | X          | X          |            |            |            |
| Escrita do artigo científico              |            |            | X          | X          |            |
| Submissão do artigo                       |            |            |            | X          |            |
| Revisão e formatação final da dissertação |            |            |            | X          | X          |
| Defesa da dissertação                     |            |            |            |            | X          |

A modelagem do SAD segue o mesmo pipeline metodológico descrito no Capítulo 3, com ajuste independente de hiperparâmetros e limiar de decisão. A análise comparativa entre os dois transtornos subsidiará a escrita do artigo científico, que reunirá os resultados de GAD e SAD em uma única submissão. A etapa final concentra a revisão textual, a formatação conforme as normas da UCPel e os ajustes solicitados na qualificação, antecedendo a defesa.

## REFERÊNCIAS

- ACHENBACH, T. M.; RESCORLA, L. A. **Manual for the ASEBA Preschool Forms and Profiles**. Burlington: University of Vermont, Research Center for Children, Youth, and Families, 2000.
- ACHENBACH, T. M.; RESCORLA, L. A. **Manual for the ASEBA Preschool Forms and Profiles**. Burlington, VT: University of Vermont, Research Center for Children, Youth, and Families, 2000.
- ASBAHR, F. R. Transtornos ansiosos na infância e adolescência: aspectos clínicos e neurobiológicos. **Jornal de Pediatria**, v. 80, n. 2, p. S28–S34, 2004.
- BROWNLEE, J. **Data Preparation for Machine Learning: Data Cleaning, Feature Selection, and Data Transforms in Python**. 1.1. ed. [S.l.]: Machine Learning Mastery, 2020. Disponível eletronicamente.
- BROWNLEE, J. **Imbalanced Classification with Python: Choose Better Metrics, Balance Skewed Classes, and Apply Cost-Sensitive Learning**. 1.2. ed. [S.l.]: Machine Learning Mastery, 2020. Disponível eletronicamente.
- CAIRES, M. C.; SHINOHARA, H. Transtornos de ansiedade na criança: um olhar nas comunidades. **Revista Brasileira de Terapias Cognitivas**, v. 6, n. 1, 2010.
- CARPENTER, K. L. H. et al. Quantifying risk for anxiety disorders in preschool children: A machine learning approach. **PLoS ONE**, Public Library of Science, v. 11, n. 11, p. e0165524, 2016.
- CARUANA, R. et al. Intelligible models for healthcare: Predicting pneumonia risk and hospital 30-day readmission. In: 21TH ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 2015, Sydney, Australia. **Proceedings...** [S.l.], 2015. p. 1721–1730.
- EGGER, H. L.; ANGOLD, A. The preschool age psychiatric assessment (papa): A structured parent interview for diagnosing psychiatric disorders in preschool children. In: DELCARMEN-WIGGINS, R.; CARTER, A. (Ed.). **Handbook of Infant, Toddler, and Preschool Mental Health Assessment**. New York: Oxford University Press, 2004. p. 223–243.
- EGGER, H. L.; ANGOLD, A. Common emotional and behavioral disorders in preschool children: presentation, nosology, and epidemiology. **Journal of Child Psychology and Psychiatry**, v. 47, n. 3–4, p. 313–337, 2006.
- EGGER, H. L. et al. Test-retest reliability of the preschool age psychiatric assessment (papa). **Journal of the American Academy of Child and Adolescent Psychiatry**, v. 45, n. 5, p. 538–549, 2006.
- EGGER, H. L. et al. Test-retest reliability of the preschool age psychiatric assessment (papa). **Journal of the American Academy of Child & Adolescent Psychiatry**, Elsevier, v. 45, n. 5, p. 538–549, 2006.



ESKANDAR, K. Artificial intelligence in psychiatric diagnosis: challenges and opportunities in the era of machine learning. **Debates em Psiquiatria**, v. 14, p. 1–16, 2024.

FRANZ, L. et al. Preschool anxiety disorders in pediatric primary care: prevalence and comorbidity. **Journal of the American Academy of Child and Adolescent Psychiatry**, v. 52, n. 12, p. 1294–1303, 2013.

GÉRON, A. **Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems**. 2. ed. Sebastopol, CA: O'Reilly Media, Inc., 2019. ISBN 978-1-492-03264-9.

GHANDOUR, R. M. et al. Prevalence and treatment of depression, anxiety, and conduct problems in us children. **The Journal of Pediatrics**, v. 206, p. 256–267, 2019.

HAQUE, A. et al. Early detection of paediatric and adolescent obsessive-compulsive, separation anxiety... **Health Information Science and Systems**, v. 11, n. 31, 2023.

LANDIS, J. R.; KOCH, G. G. The measurement of observer agreement for categorical data. **Biometrics**, v. 33, n. 1, p. 159–174, 1977.

LIU, G.-D. et al. A brief review of artificial intelligence applications and algorithms for psychiatric disorders. **Engineering**, Elsevier, v. 6, n. 4, p. 462–467, 2020.

MCGINNIS, E. W. et al. Rapid detection of internalizing diagnosis in young children enabled by wearable sensors and machine learning. **PLoS ONE**, v. 14, n. 1, 2019.

MENG, J. F.; WIZNITZER, E. Factors associated with not receiving mental health services among children with a mental disorder in early childhood in the united states, 2021–2022. **Preventing Chronic Disease**, v. 21, p. 240126, 2024.

MIAN, N. D.; DARLING, L. N.; CARTER, A. S. Anxiety disorders in young children: Phenomenology, identification, and diagnosis. **Psychiatric Annals**, SLACK Incorporated, v. 55, n. 4, p. e80–e85, 2025.

SHATTE, A. B. R.; HUTCHINSON, D. M.; TEAGUE, S. J. Machine learning in mental health: a scoping review of methods and applications. **Psychological Medicine**, Cambridge University Press, v. 49, n. 9, p. 1426–1448, 2019.

SPENCE, S. H. et al. The structure of anxiety symptoms among preschoolers. **Behaviour Research and Therapy**, v. 39, n. 11, p. 1293–1316, 2001.

VIANA, M. B. Freud e darwin: ansiedade como sinal, uma resposta adaptativa ao perigo. **Natureza Humana**, v. 12, n. 1, 2010.

ZHAI, Y. et al. Machine learning predictive models to guide prevention and intervention allocation for anxiety and depressive disorders among college students. **Journal of Counseling & Development**, Wiley, v. 103, p. 110–125, 2025.